Explicando Modelos YOLO e suas variações

1- O que é o YOLO e como funciona?

O YOLO (You Only Look Once) é uma arquitetura de rede neural desenvolvida para a detecção de objetos em tempo real. Diferente de algoritmos tradicionais de dois estágios, o YOLO formula a detecção como um único problema de regressão direta.

Processamento em Etapa Única: A rede analisa a imagem inteira de uma só vez através de uma única passagem pela CNN, prevendo simultaneamente as caixas delimitadoras (bounding boxes) e a probabilidade de cada classe.

Divisão em Grade (Grid): A imagem é dividida em uma grade (ex: 16×16). A célula na qual o centro de um objeto se encontra fica encarregada de prever suas coordenadas (x, y, w, h) e o nível de confiança.

2- Paradigmai: Anchor Based vs Anchor Free:

As versões clássicas do YOLO dependiam de anchor boxes (formatos fixos pré-definidos). As versões modernas adotam a abordagem Anchor-free, onde o modelo prevê diretamente o centro do objeto e as distâncias até as quatro bordas. Isso elimina o ajuste manual de âncoras e melhora a regressão em objetos atípicos.

3- MODELO A: YOLO ANCHOR-FREE COM CABEÇA EXTRA P2

O Modelo A foca na adição de uma nova escala de detecção voltada exclusivamente para objetos de pequena dimensão espacial (como minas aquáticas em sonar de varredura lateral).

Mecanismo da Cabeça P2 (P2 Head): Redes convolucionais tradicionais utilizam escalas P3 ($1/8$), P4 ($1/16$) e P5 ($1/32$). Em objetos com poucos pixels, os detalhes desaparecem em camadas profundas como P4 e P5. A cabeça P2 adiciona um ramo de detecção em escala $1/4$ da resolução original, preservando características espaciais finas antes da perda de informação.

Mecanismo Anchor-free: Previsão direta do centro do alvo sem depender de formatos fixos.

Aplicação Principal: Alvos que ocupam uma área muito reduzida da imagem.

4- MODELO B: YOLO COM ATENÇÃO CBAM E SPD-CONV

O Modelo B ataca a perda de detalhes finos dentro do próprio backbone da rede, combinando mecanismos de atenção espacial/canal e reestruturação de amostragem.

Módulo de Atenção CBAM: Combina Channel Attention (descobre o quê focar nos canais) e Spatial Attention (descobre onde focar na imagem). Ajuda a filtrar ruídos de fundo (como o relevo marinho em dados de sonar) e destaca o alvo.

Camadas SPD-Conv: Substitui as convoluções com stride > 1 ou pooling tradicionais. Transfere pixels do espaço para a profundidade (Space-to-Depth), realizando a redução de tamanho sem descartar informações finas de objetos pequenos.

5- Comparação

Característica	Modelo A P2 Head	Modelo B CBAM/SPD-Conv
Foco Principal	Adição de camada de alta resolução ($1/4$).	Reformulação do backbone e amostragem sem perda
Amostragem Downsampling	Tradicional no backbone, recuperado na P2.	Sem perda de informação via SPD-Conv.
Filtragem de Ruído	Baseada em maior resolução espacial	Aprimorada via Atenção CBAM (Canal + Espaço).
Previsão de Caixas	Totalmente Anchor	Anchor-Free aperfeiçoado.

6- Referencias e fontes

https://www.ultralytics.com/glossary/anchor-free-detectors

https://www.ultralytics.com/blog/benefits-ultralytics-yolo11-being-anchor-free-detector

https://arxiv.org/html/2606.09081v1

https://github.com/labsaint/spd-conv

http://scholar-press.com/uploads/papers/TU9pwX120sAvcgsut6buyQa408Mzxt0uMRrif2sl.pdf